

TEXT-TO-MASK VISION

Как превратить текстовый запрос в маски объектов

Grounding DINO находит boxes по prompt, SAM строит маски. Я проверяю не “идеальную модель”, а воспроизводимый практический pipeline.

Radmir Islamov

GitHub: github.com/Therad445/text-to-mask-vision



Text-to-mask result: bear .




image + “bear .” → boxes → masks



ЧТО Я ПОКАЖУ

- 1 Зачем нужен text-to-mask pipeline
- 2 Как связаны Grounding DINO, NMS и SAM
- 3 Что реализовано в коде и demo
- 4 Как проверял поведение на 5 кейсах
- 5 Где система ломается и почему это важно

Главный тезис: ценность проекта — не обучение новой модели, а сборка воспроизводимого CV-инструмента из foundation models.



ПОЧЕМУ FIXED-CLASS DETECTION НЕУДОБЕН

Обычный detector знает фиксированный набор классов. Для быстрого прототипирования этого часто мало.

Fixed-class detector


- заданный список классов
- меньше интерактивности
- новые объекты требуют данных

Text-to-mask

- prompt на естественном языке
- open-vocabulary detection
- маски без обучения под класс

Я хотел проверить: можно ли быстро перейти от “я хочу найти это” к готовым маскам на изображении?

ЧТО ИМЕННО Я ПРОВЕРЯЛ




input image

Вопрос проекта:

Можно ли собрать практичный pipeline, который по изображению и текстовому prompt выдаёт маски объектов без обучения под новый класс?

- 1 Работает end-to-end
- 2 Есть интерактивное demo
- 3 Есть анализ успехов и ошибок

ПАЙПЛАЙН: ОТ ТЕКСТА К МАСКЕ



Важное понимание: в этой связке SAM не исправляет плохую локализацию — он строит маску по тем boxes, которые дал detector.



ЧТО БЫЛО РЕАЛИЗОВАНО

Project check passed.

Я вынес логику из notebook в отдельный pipeline, чтобы проект можно было запускать и проверять повторно.

Core pipeline

src/text_to_mask_pipeline.py

model loading, detection, NMS, segmentation

Interactive layer

app.py

Streamlit UI, thresholds, output table

Experiment layer

notebooks + gallery CSV

sanity check, batch gallery, figures

Quality layer


check_project.sh

syntax, artifacts, no local weights

ИНТЕРАКТИВНОЕ DEMO

- image upload
- prompt + thresholds
- NMS IoU
- detections table
- mask visualization

```
python -m streamlit run app.py
```



Для защиты demo открывается с финальным preset: box=0.25, text=0.30, NMS=0.35, max=8.



КАК Я ПРОВЕРЯЛ СИСТЕМУ

Success

bus . person .
person .

Prompt sensitivity


bear . vs bear cub .
bus . person . vs small animal .

Failure analysis

crowded bears

Это не supervised benchmark: я использую визуальную проверку + proxy scores пайплайна и честно фиксирую ограничения.

КОГДА OPEN-VOCABULARY CONTROL РАБОТАЕТ ХОРОШО



Prompt: bus . person .

- bus найден с высокой уверенностью
- несколько person-инстансов
- маски строятся из selected boxes
- хороший пример prompt control


0.709

mean box score


0.962

mean mask score

PROMPT МЕНЯЕТ СМЫСЛ РЕЗУЛЬТАТА



`bus . person .` → осмысленные detections




`small animal .` → ниже confidence и неверная семантика

Гибкость open-vocabulary моделей имеет цену: часть качества переносится на формулировку prompt.

САМЫЙ ЧЕСТНЫЙ КЕЙС: МЕДВЕДИ В ТОЛПЕ

Text-to-mask result: bear .



Финальные параметры

prompt bear .

box 0.25

text 0.30

NMS 0.35

max 8

final 5

0.399

mean box score

0.971

mean mask score

Вывод: bottleneck — detection/localization в overlap-сцене; SAM стабилен, если boxes выбраны разумно.

ЧТО ПОЛУЧИЛОСЬ И ГДЕ ГРАНИЦЫ

Получилось

- end-to-end text-to-mask pipeline
- Streamlit demo
- воспроизводимый repo
- gallery success/failure cases

Ограничения

- нет labeled benchmark
- crowded scenes ломают detector
- prompt влияет на результат
- latency/GPU deployment — future work

Я сфокусировался на reproducible practical system, а не на обучении новой модели с нуля.

СПАСИБО

Главный результат:

я собрал и проверил практическую связку foundation models, которая превращает текстовый запрос в маски объектов и показывает, где проходит граница между красивым demo и реальной надёжностью.

GitHub: github.com/Therad445/text-to-mask-vision

Вопросы?

